

# dbarc: Ausarbeitung SQLTuning

Yanick Eberle, Pascal Schwarz

13. April 2013

## 1 Einleitung

## 2 Statistiken

### 2.1 Statistiken sammeln

Mit dem folgenden Befehl werden die Statistiken für alle Tabellen aufgebaut:

```
1 BEGIN
2   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','customers');
3   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','lineitems');
4   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','nations');
5   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','orders');
6   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','parts');
7   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','partsupps');
8   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','regions');
9   DBMS.STATS.GATHER_TABLE_STATS('dbarc02','suppliers');
10 END;
```

### 2.2 Zeilen, Bytes, Blöcke und Extents der Tabellen

Um die Anzahl Extents festzustellen, haben wir uns Informationen der Tabelle *DBA\_SEGMENTS* bedient. Eine kurze Google-Recherche führte uns auf die Seite <http://www.rocket99.com/techref/oracle8409.html>, die uns bei dieser Aufgabe behilflich war.

```
1 SELECT stat.table_name, stat.num_rows, stat.blocks, seg.extents,
2        stat.avg_row_len*stat.num_rows AS size_bytes
3 FROM user_tab_statistics stat
4 JOIN DBA_SEGMENTS seg ON (stat.table_name = seg.segment_name)
5 WHERE seg.owner = 'DBARC02'
```

TABLENAME	NUMROWS	BLOCKS	EXTENTS	SIZE_BYTES
CUSTOMERS	150000	3494	43	23850000
LINEITEMS	6001215	109217	179	750151875
NATIONS	25	4	1	2675
ORDERS	1500000	24284	95	166500000
PARTS	200000	3859	46	26400000
PARTSUPPS	800000	16650	88	114400000
REGIONS	5	4	1	480
SUPPLIERS	10000	220	17	1440000

### 3 Ausführungsplan

Die Ausführung des EXPLAIN PLAN-Befehles erzeugt folgende Ausgabe:

```
1 plan FOR succeeded.
```

Und die Abfrage des Ausführungsplans zeigt erwartungsgemäss einen kompletten Tabellenzugriff, da das SELECT-Statement ja keine WHERE-Klausel verwendet.

```
1 PLAN.TABLE.OUTPUT
2
3 Plan hash value: 3931018009
4
5
6 | Id | Operation | Name | Rows | Bytes | Cost (%CPU) | Time |
7
8 | 0 | SELECT STATEMENT | | 200K | 25M | 1051 (1) | 00:00:13 |
9 | 1 | TABLE ACCESS FULL | PARTS | 200K | 25M | 1051 (1) | 00:00:13 |
10
```

### 4 Versuche ohne Index

#### 4.1 Projektion

##### 4.1.1 \* FROM

Das erste Statement (SELECT \* FROM...) erzeugt einen Output sehr ähnlich dem bereits Gezeigten. Es werden sämtliche 1.5 Millionen Zeilen der Tabelle gelesen. Da es sich dabei primär um I/O handelt, ist der Anteil der CPU an den Kosten mit lediglich einem Prozent entsprechend gering.

```
1
2 | Id | Operation | Name | Rows | Bytes | Cost (%CPU) | Time |
3
4 | 0 | SELECT STATEMENT | | 1500K | 158M | 6610 (1) | 00:01:20 |
5 | 1 | TABLE ACCESS FULL | ORDERS | 1500K | 158M | 6610 (1) | 00:01:20 |
6
```

##### 4.1.2 o\_clerk FROM

Bei der Projektion auf eine einzige Spalte der Tabelle Orders fällt ein Grossteil der Daten weg (22M statt 158M), ansonsten sind die Unterschiede aber sehr gering. Vom Festspeicher müssen die selben Blöcke gelesen werden, erst danach können die Inhalte der nicht angefragten Spalten verworfen werden. Daher fallen auch die Kosten nur geringfügig tiefer aus.

```
1
2 | Id | Operation | Name | Rows | Bytes | Cost (%CPU) | Time |
3
4 | 0 | SELECT STATEMENT | | 1500K | 22M | 6607 (1) | 00:01:20 |
5 | 1 | TABLE ACCESS FULL | ORDERS | 1500K | 22M | 6607 (1) | 00:01:20 |
6
```

### 4.1.3 DISTINCT o\_clerk FROM

Für das SELECT DISTINCT Statement werden in einem ersten Schritt (Id:2) wiederum alle Daten der entsprechenden Spalte der Tabelle geladen (Kosten wiederum 6607). Danach werden mittels HASH UNIQUE die doppelt vorhandenen Werte ermittelt und entfernt. Dies erzeugt noch ein wenig CPU-Last, aber senkt die Anzahl Zeilen von 1.5 Millionen auf 1000 und verringert dadurch auch den Speicherbedarf von 22M auf 16000 Bytes.

Id	Operation	Name	Rows	Bytes	Cost	(%CPU)	Time
0	SELECT STATEMENT		1000	16000	6676	(2)	00:01:21
1	HASH UNIQUE		1000	16000	6676	(2)	00:01:21
2	TABLE ACCESS FULL	ORDERS	1500K	22M	6607	(1)	00:01:20

## 4.2 Selektion

### 4.2.1 Exact Point

Obwohl das Exact-Point Query lediglich eine einzige Zeile zurückliefert fallen die Kosten mit 6602 beinahe so hoch wie bei der Projektion auf eine einzige Spalte der selben Tabelle (ohne Selektion) aus. Da kein Index für diese Spalte vorhanden ist, kann das Datenbanksystem die Abfrage nicht effizienter als mittels linearer Suche ausführen.

Id	Operation	Name	Rows	Bytes	Cost	(%CPU)	Time
0	SELECT STATEMENT		1	111	6602	(1)	00:01:20
* 1	TABLE ACCESS FULL	ORDERS	1	111	6602	(1)	00:01:20

Predicate Information (identified by operation id):

1 - filter ("O.ORDERKEY"=44444)

### 4.2.2 Partial Point, OR

Die OR-Verknüpften Bedingungen und die daraus resultierende höhere Anzahl an zurückzugebenden Zeilen erhöhen die Kosten gegenüber dem Exact Point Query noch ein wenig. Weiterhin dürfte aber die Notwendigkeit des Lesens der gesamten Tabelle für die lineare Suche den grössten Teil der Kosten ausmachen.

Id	Operation	Name	Rows	Bytes	Cost	(%CPU)	Time
0	SELECT STATEMENT		1501	162K	6629	(1)	00:01:20
* 1	TABLE ACCESS FULL	ORDERS	1501	162K	6629	(1)	00:01:20

Predicate Information (identified by operation id):

1 - filter ("O.CLERK"='Clerk #000000286' OR "O.ORDERKEY"=44444)

**4.2.3 Partial Point, AND**

**4.2.4 Partial Point, AND und Funktion**

**4.3 Join**

## **5 Versuche mit Index**

**5.1 Erzeugung Indices**

**5.2 Projektion**

**5.3 Selektion**

**5.4 Join**